SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

PROJEKT IZ RAČUNALNOG VIDA

Raspoznavanje preklapajućih 2D objekata

Tomislav Babić Mateja Čuljak Đorđe Grbić Ivan Krišto
Maja Šverko

Zagreb, siječanj 2011.

Sadržaj

1. Projektni zadatak

1.1. Opis projektnog zadatka

Cilj projekta je razvijanje sustava računalnog vida za klasifikaciju preklapajućih $2D$ objekata. Skup objekata koji se klasificiraju je unaprijed poznat. Pod pojmom "preklapanje" uzimaju se u obzir sljedeća pravila:

- objekti se međusobno preklapaju,
- moguće je da objekt ne sudjeluje u preklapanju (tj. objekt je samostalan),
- svaki objekt prekriven je najviše jednim objektom,
- razine preklapanja su proizvoljne,
- rotacija, skaliranje i pomak objekata su proizvoljni,
- boja objekta je proizvoljna.

Ulaz sustava u fazi inicijalizacije je skup samostalnih objekata koje želimo klasificirati. U fazi raspoznavanja sustavu predajemo sliku koja sadrži preklapajuće objekte. Izlaz sustava su nazivi objekata koji se nalaze na slici te njihove vjerojatnosti da sudjeluju u preklapanju.

1.2. Konceptualno rješenje zadatka

Algoritmi i koncepti korišteni u rješavanju zadatka:

Binarizacija slike pragom: Ulazni podatci su slike u *jpg* formatu. Izlazni podatci su binarne slike.

Izlučivanje značajki: Riječ je zapravo o pronalasku linearnih segmenata konture u sceni, odnosno pronalasku rubova u sceni te aproksimacija rubova poligonima. Ulazni podatci su binarne slike, a izlaz vektor segmenata.

Generiranje hipoteza: Usporedba linearnih segmenata konture u slici sa segmentima iz modela u bazi podataka skupa za učenje. Ulazni podatci su vektori segmenata, a izlazni podatci generirane hipoteze, točnije, mjere sličnosti kompatibilnih linearnih segmenata.

Evaluacija hipoteza: Nakon generiranja hipoteza potrebno je iste evaluirati. Odnosno, usporediti i ostale linearne segmente sa segmentima modela. Ulazne podatke predstavljaju generirane hipoteze, a izlazni podatci su hipoteze sortirane na način da prva odgovara najbolje procijenjenoj hipotezi, a posljednja najgore procijenjenoj hipotezi.

Izlaz sustava su nazivi klasa objekata (iz najbolje procijenjenih hipoteza) koji sudjeluju u preklapanju unutar nove scene.

2. Postupak rješavanja zadatka

Sustav je zamišljen tako da se sastoji od četiri osnovne komponente:

- komponente za učitavanje i spremanje slika,
- filtera slika,
- vaditelja značajki objekata na slikama,
- algoritma za raspoznavanje.

Filter slika priprema slike za postupak vađenja značajki, primjerice, pretvara RGB sliku u binarnu. Vaditelj značajki zapisuje objekte na slikama u format prilagođen algoritmu raspoznavanja.

Sustav raspoznavanja treba biti robustan i otporan na što veći broj konfiguracija preklapanja. Navedeni zahtjev podrazumijeva da će algoritam raspoznavanja te značajke koje on koristi moći nesmetano funkcionarati i u uvjetima kad su:

- objekti proizvoljno rotirani,
- objekti proizvoljno skalirani,
- objekti proizvoljno smješteni u ravnini,
- površine preklapanja različite,
- objekti jednake boje.

Opisan rad sustava možemo promatrati kroz dva koraka – inicijalizaciju i raspoznavanje objekata scene. Prilikom inicijalizacije, za svaki objekt koji želimo klasificirati sustavu predočavamo scenu koja sadrži samo taj objekt. Sustav vadi značajke i sprema ih. U koraku raspoznavanja, sustav na ulazu dobiva sliku scene u kojoj se nalaze preklopljeni objekti, koristi spremljene značajke neprekloplјenih objekata, vadi značajke objekata unutar nove scene te uspoređuje značajke objekata nove scene sa spremljenim značajkama. Navedeni korak rješenja se zasniva na konceptima opisanim u [1].

2.1. Poligonizacija objekata

2.1.1. Dobivanje binarne slike iz slike u boji

Slika u boji se prvo pretvara u sivu sliku, gdje se vrijednost slikovnog elementa sive slike računa kao vrijednost osvijetljenosti (engl. *luminance*) s na sljedeći način:

$$s = r \cdot 0.3 + g \cdot 0.59 + b \cdot 0.1,$$

gdje su r, g i b komponente slikovnog elementa slike u RGB prostoru boja. Nakon toga se siva slika pretvara u binarnu. Slikovni element se uspoređuje s pragom te ako mu je vrijednost veća od praga, tada će on poprimiti iznos jednak nuli. U suprotnom slučaju slikovni element poprima vrijednost 255.

2.1.2. Algoritam za praćenje granice

Algoritam se izvodi na sljedeći način:

1. Provjeriti sastoji li se objekt od jednog izoliranog slikovnog elementa. Ako je to istina, taj element je ujedno i granica. U tom slučaju zaustaviti postupak.
2. Pretraživanjem slike naći dva susjedna elementa, $c \in S$ i $d \in \bar{S}$, pri čemu je S skup točaka koje pripadaju objektu (povezanoj slikovnoj komponenti).
3. Promijeniti vrijednost točke c u 3, a točke d u 2.
4. Označiti 8-susjedstvo točke c sa $e_1, e_2, \ldots, e_k$ počevši od točke d, u smjeru kazaljke na satu, i zaustavivši se s prvim pojavljivanjem broja 1, 3 ili 4.
5. Ako je $c = 3, e_k = 4, e_h = 2$ za neki $h < k$, promijeni 3 u 4, 2 u 0 te se zaustavi.
6. Inače, promijeni vrijednost c u 4, ako je prije toga imao vrijednost 1. Kao novu vrijednost za c uzmi e_k, a za d uzmi e_{k-1}. Ponavljaj sve od 4. koraka.

Nakon završetka algoritma, slikovni elementi koji imaju vrijednost 4 predstavljaju granicu objekta.

2.1.3. Podijeli i vladaj algoritam za segmentaciju ruba

Algoritam podijeli-i-vladaj se koristi kad se rub može prikazati jednostavnijim funkcijskim oblicima, te kad su poznate krajnje točke granice (dva rubna elementa).

Algoritam se izvodi na sljedeći način:

1. Povući pravocrtnu liniju između dvije krajnje točke granice.
2. Izračunati pravokutne udaljenosti za svaki slikovni element koji je rubni element i nalazi se u području granice.
3. Usporediti dobivene udaljenosti s unaprijed zadanim pragom τ.
4. Ako su sve udaljenosti manje od τ, zaustaviti algoritam.
5. Rubni element s najvećom udaljenošću postaje prijelomna točka. Prošli linijski segment se zamjenjuje s novim linijskim segmentima (tj. linijama od krajnjih točaka prema prijelomnoj točki).
6. Rekurzivno izvesti algoritam koristeći nove linijske segmente.

Eksperimentalno je odabran prag τ u iznosu od 10 piksela.

Točke pronađene algoritmom praćenja granica se dijele na dva skupa. Prvi skup obuhvaća sve točke od prve do središnje, a drugi skup obuhvaća preostali skup točaka. Podijeli i vladaj algoritam se izvodi nad oba skupa zasebno te se dobivaju dva skupa linearnih segmenata. Kako bi se dva skupa spojila u jedan, potrebno je spojiti uzastopne segmente slične orijentacije. Ako je razlika orijentacija manja od zadanog praga, segmenti se spajaju. Prag korišten u implementaciji postupka iznosi 15 stupnjeva.

2.2. Generiranje hipoteza

Ulazni skup podataka prilikom generiranja hipoteza čine vektori segmenata slika za učenje (u daljem tekstu slike modela) i slika za testiranje (u daljnjem tekstu slike scene). Svaka hipoteza je zapravo pretpostavka da određen segment scene odgovara određenom segmentu modela. U obzir se pritom uzimaju samo kompatibilni segmenti. Kompatibilnost je u ovom slučaju definirana dvama pragovima. Prvi prag određuje razliku među kutovima A između segmenta modela i njegovog prethodnika te kuta A' između segmenta scene i njegovog prethodnika. Drugi prag određuje omjer u duljini dvaju segmenata.

Transformacija T koja može poslužiti za olakšavanje usporedbe dvaju segmenata definirana je u literaturi [1] i glasi ovako:

$$x^* = tx + x \cdot k \cdot \cos(\beta) - y \cdot k \cdot \sin(\beta), \tag{2.1}$$

$$y^* = ty + y \cdot k \cdot \cos(\beta) + y \cdot k \cdot \sin(\beta). \tag{2.2}$$

Koeficijenti tx, ty, k i β mogu se izračunati na sljedeći način:

$$k = l(S_i)/l(M_i), \tag{2.3}$$

$$\beta = a(S_i) - a(M_i), \tag{2.4}$$

$$tx = x' - k \cdot (x \cdot \cos(\beta) - y \cdot \sin(\beta)), \tag{2.5}$$

$$ty = y' - k \cdot (x \cdot \sin(\beta) + y \cdot \cos(\beta)), \tag{2.6}$$

gdje je S_i linearni segment u sceni, M_i linearni segment modela, l je duljina segmenta, β je kut između segmenta i horizontalne osi, a x', y' predstavljaju koordinate središnjih točaka segmenta. Generirane hipoteze spremaju se u vektor hipoteza.

2.3. Evaluacija hipoteza

2.3.1. Sparivanje dodatnih linearnih segmenata

Nakon generiranja hipoteza potrebno je iste evaluirati, pri čemu se iterativno uspoređuju preostali linearni segmenti modela sa segmentima scene.

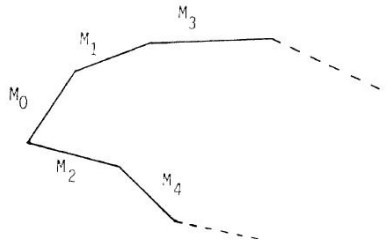

Slika 2.1: Redoslijed odabira segmenata iz modela.

Algoritam u svakoj iteraciji odabire segment M_i iz modela (slika 2.1) i izračunava njegov položaj u sceni trenutnom transformacijom. Nakon toga se uspoređuje različitost transformiranog segmenta modela, tM_i sa svakim segmentom u sceni, S_j. Mjera sličnosti d_{ij} između segmenata tM_i i S_j može se izraziti pomoću tri mjere:

1. a_{ij} je mjera koja se računa kao apsolutna vrijednost razlike između segmenata tM_i i S_j,

2. D_{ij} se računa kao Euklidska udaljenost između središnjih točaka segmenata tM_i i S_j,

3. l_{ij} se računa kao relativna udaljenost između duljina segmenata tM_i i S_j te odgovara sljedećem izrazu: $l_{ij} = (l'_i - l_j)/l_j$, gdje je l'_i duljina segmenta tM_i, a l_j duljina segmenta S_j.

Svaka od tih mjera ograničena je pripadnom gornjom vrijednošću a_{Max}, D_{Max} ili l_{Max} koje u trenutnoj implementaciji iznose: $a_{Max} = 0.35$, $D_{Max} = 45$ ili $l_{Max} = 0.7$.

Ukoliko neka od tih mjera ima iznos veći od svoje gornje granice, tada je $d_{ij} = 1$, inače mjera različitosti se računa na sljedeći način:

$$d_{ij} = p \cdot a_{ij}/a_{Max} + q \cdot D_{ij}/D_{Max} + r \cdot l_{ij}/l_{Max}, \tag{2.7}$$

gdje su p, q, r pozitivne težine čija suma iznosi 1. U trenutnoj implementaciji njihove vrijednosti su: $p = 0.6$, $q = 0.3$, $r = 0.1$.

Segment M_i je sparen sa segmentom S_j kada je d_{ij} najmanjeg iznosa i manji od 1. Ukoliko za nijedan segment scene S_j, d_{ij} nije iznosa manjeg od 1, tada segment M_i nema par u sceni.

2.3.2. Ažuriranje transformacije

Nakon što su segmenti M_i i S_j spareni, potrebno je izvršiti ažuriranje hipoteze korištenjem rekurzivne metode najmanjih kvadrata. Cilj je pronaći transfomaciju T koja minimizira kriterij:

$$R = \sum_i \frac{l_i}{K} \Delta^2(T(m_i), s_{ji}),$$

gdje su m_i i s_{ji} središnje točke segmenata M_i i S_j. Δ je oznaka za euklidsku udaljenost, dok je l_i duljina segmenta M_i. K je konstanta koja se u trenutnoj implementaciji dobiva izrazom: $K = D_{Max} \cdot l_{Mean}$, gdje je l_{Mean} prosječna duljina segmenata u modelu, a D_{Max} je definiran u prethodnom potpoglavlju.

Ako predstavimo transformaciju T pomoću vektora

$$v = (k \cdot \cos\beta, k \cdot \sin\beta, tx, ty)^T$$

te točku s_{ji} s koordinatama x'_i i y'_i predstavimo vektorom $Y_i = (x'_i, y'_i)^T$ možemo prethodni izraz zapisati kao:

$$R = \sum_i (Y_i - C_i v)^T W_i^{-1} (Y_i - C_i v).$$

Matrica C_i je dana sljedećim izrazom:

$$C_i = \begin{bmatrix} x_i & -y_i & 1 & 0 \\ y_i & x_i & 0 & 1 \end{bmatrix},$$

gdje su x_i i y_i koordinate središnje točke segmenta modela m_i. Matrica W_i je dana izrazom:

$$W_i = \begin{bmatrix} w_i^2 & 0 \\ 0 & w_i^2 \end{bmatrix},$$

gdje vrijedi $w_i = K/l_i$.

Kako bi se mogli kontrolirati parametri transformacije T, u minimizacijski kriterij dodan je dodatni član, pa se izraz naposlijetku može zapisati na sljedeći način:

$$R = \sum_i (Y_i - C_i v)^T W_i^{-1} (Y_i - C_i v) + (v - v_0)^T S_0^{-1} (v - v_0).$$

R je kvadratni kriterij koji se može rekurzivno minimizirati sljedećim jednadžbama:

$$\begin{aligned} v_i &= v_{i-1} + K_i (Y_i - C_i \cdot v_i), \\ K_i &= S_{i-1} C_i^T (W_i + C_i S_{i-1} C_i^T)^{-1}, \\ S_i &= (l + K_i C_i) S_{i-1}. \end{aligned}$$

Ove jednadžbe se inicijaliziraju za svaku hipotezu te se rekurzivno ažuriraju nakon svakog sparivanja segmenata modela i scene.

3. Evaluacija rješenja

3.1. Opis baze uzoraka

Baza uzoraka sastoji se od 120 slika koje sadrže dvanaest različitih oblika izrađenih od tvrdog papira; šest jednostavnijih i šest kompleksnijih. Za svaki od dvanaest oblika postoji 10 slika; dvije slike samog oblika (različite po veličini, rotaciji i translaciji) i 8 različitih slika oblika prekrivenog drugim oblikom. Dimenzije uzoraka su 900×600 piksela. Oblici se jasno razaznaju od pozadine, no ponegdje bacaju blijedu sjenu zbog blage savijenosti oblika. Sve slike preklapanja sadrže oblike različitih boja, međutim u implementaciji rada se ta informacija ne koristi.

Imenovanje scene je vršeno po formatu "`m1m2[a-z].jpg`". Oznaka `m1` označava kod donjeg modela (npr. 12 za kapljicu, 01 za kvadrat), `m2` gornjeg modela, "`[a-z]`" broj pojave kombinacije – primjerice ako se pojavljuju dvije scene u kojima je kapljica na kvadratu, tada imamo scene `0112a.jpg` i `0112b.jpg`. Nepravilnost u formatu postoji kod oznake modela i njegovog transformiranog oblika. Oznaka `m100` označava samostalni transformirani (rotirani, skalirani i malo translatiran) objekt, a oznaka `m101` **ne označava** kvadrat na modelu `m1` već sam model. Kvadrat na modelu `m1` označava se dodatnim slovima, odnosno: `m101.jpg` je slika modela, ali `m101a.jpg` je slika kvadrata na modelu.

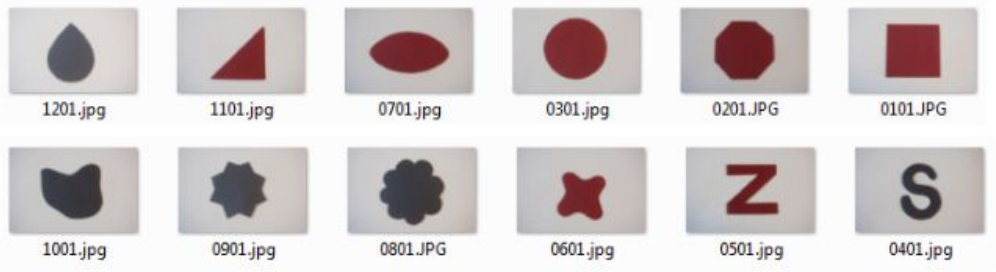

Slika 3.1: Prikaz objekata za klasifikaciju.

3.2. Rezultati i analiza evaluacije

Pri evaluaciji korištene su sve slike iz baze izuzev slika na kojima se pojavljuje trokut zbog prevelike sličnosti s pravokutnikom. Za svaku scenu (sliku preklapanja objekata) provedena je evaluacija u kojoj je sudjelovalo 11 modela (svi osim trokuta). Rezultat evaluacije su vjerojatnosti da se određeni model nalazi na sceni.

Problemi rotacije, skaliranja i translacije objekata javljaju se u samom početku obrade scene. Navedeni problemi su rješivi odabirom značajki koje su invarijantne na njih te dobrim parametrima metoda koje se koriste za izgradnju značajki (primjerice, poligonizaciju slike). Pri evaluaciji, parametri nisu varirani već su eksperimentalno odabrani parametri koji su se pokazali relativno dobrima (navedeni su uz svaku metodu u ostatku dokumentacije).

Bitno je napomenuti da je metoda izuzetno ovisna o prirodi baze modela i scena na koje je primjenjena, odnosno sličnostima među modelima u bazi te načinu preklapanja objekata u sceni. Složenost modela može poboljšati uspješnost klasifikacije jer se klasifikacija temelji na uspoređivanju sličnosti objekata i modela.

Mjera kvalitete pojedine hipoteze je izražena omjerom duljine segmenata modela sparenih s odgovarajućim segmentima u sceni te duljine svih segmenata modela. Maksimalna vrijednost kvalitete hipoteze je 1 te se ona postiže samo kada su svi segmenti modela spareni sa odgovarajućim segmentima scene.

Prikaz uspješnosti prepoznavanja pojedinog modela unutar scene može se vidjeti po brojevima uspješnih i neuspješnih prepoznavanja na slici 3.2.

Statistika je prikazana tablicama 3.1 i 3.2. Tablica 3.1 prikazuje uspješnost prepoznavanja povezanu sa brojem najbolje rangiranih (najvjerojatnijih) hipoteza. Kod tablice 3.2, uzeta je pretpostavka da svaka scena sadrži jedan objekt ili dva različita te je prikazana statistika uspješnosti prepoznavanja po broju prepoznatih objekata (s lijeve strane je broj uspješno prepoznatih objekata, dok je s desne broj objekata na slici). Iz tablice 3.2 možemo zaključiti da se svi objekti na sceni prepoznaju u 40% slučajeva, neovisno o tome sadrži li scena 1 ili 2 objekta. Barem jedan objekt na sceni se prepozna u 86.7% slučajeva (radi se o stupcima “1 od 1”, “1 od 2” i “2 od 2” u tablici 3.2). Tablica 3.1 je napravljena koristeći 83 slike, tablica 3.2 koristeći 105 slika. Pri izgradnji tablice 3.2 kao scene korišteni su i sami modeli (nema striktnog učenja te hold-out metoda nije neophodna). Time je metoda evaluirana za prepoznavanje neprekloplјenog objekta.

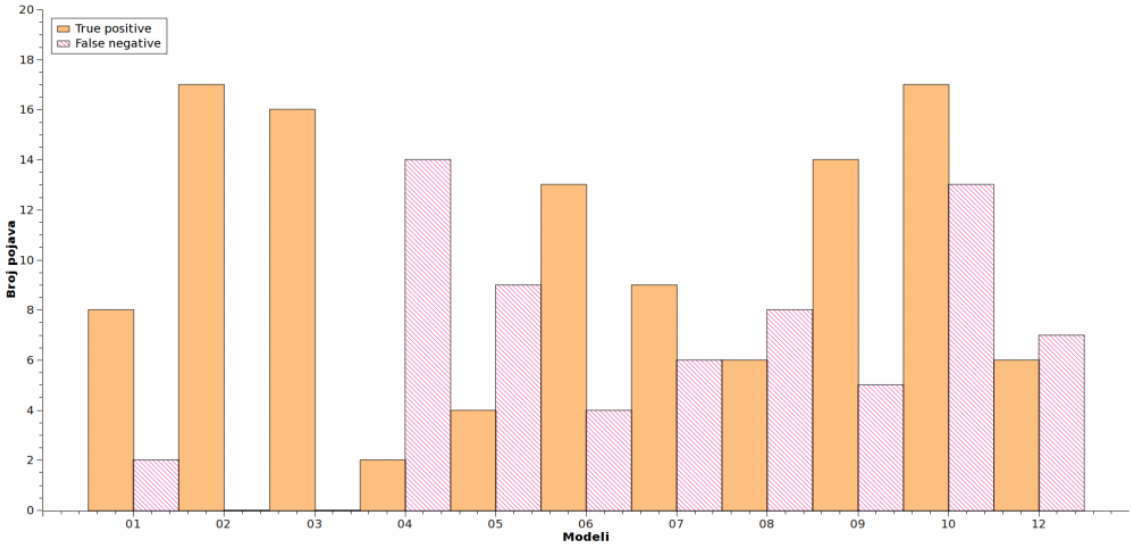

Slika 3.2: Graf uspješnih i neuspješnih prepoznavanja po modelima.

Tablica 3.1: Uspješnost prepoznavanja po hipotezama.

	2/2	2/3	2/4	1/2
Broj:	22	42	52	77
Postotak:	26.5%	50.6%	62.5%	92.8%

Objašnjenje mjera:

- 2/2 znači da su dva najbolja prijavljena objekta ispravni (dva istinito pozitivna objekta),
- 2/3 znači da su među tri najbolja prijavljena objekta dva ispravna (uključuje prijavljene objekte iz prethodne mjere),
- 2/4 znači da su među četiri najbolja prijavljena objekta sigurno dva ispravna (uključuje prijavljene objekte iz obje prethodne mjere),
- 1/2 znači da je među dva najbolja prijavljena objekta sigurno jedan ispravan (uključuje prijavljene objekte iz svih prethodnih mjera).

U nastavku je dan pokazni primjer za jednu scenu. Na sceni se preklapaju objekt s konturom elipse i zvijezda s osam vrhova, kao što se može vidjeti na slici 3.3.

Prva hipoteza tvrdi da se na sceni nalazi zvijezda s kvalitetom iznosa 63.9%. Možemo vidjeti kako su svi vidljivi segmenti zvijezde u sceni ispravno pronađeni, te da je pogrešno detektiran još jedan segment na rubu elipse. Razlog tome je u

Tablica 3.2: Uspješnost prepoznavanja po objektima.

	1 od 1	0 od 1	2 od 2	1 od 2	0 od 2
Broj:	21/22	1/28	21/83	49/83	7/83
Postotak:	95.4%	3.6%	25.3%	59.0%	8.4%

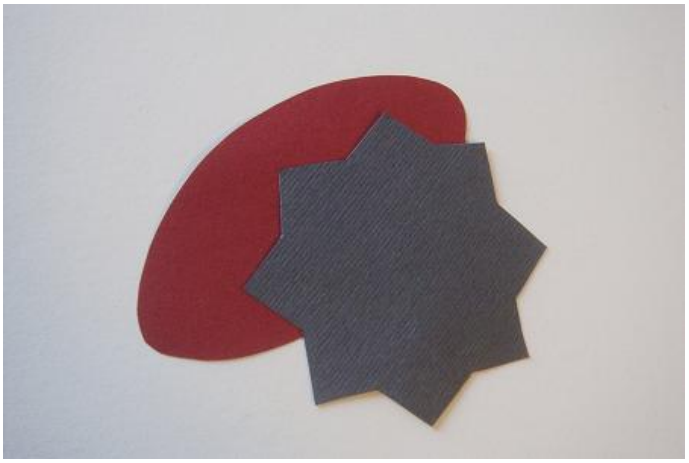

Slika 3.3: Scena s dva preklapajuća objekta koji odgovaraju modelima 0701 i 0901.

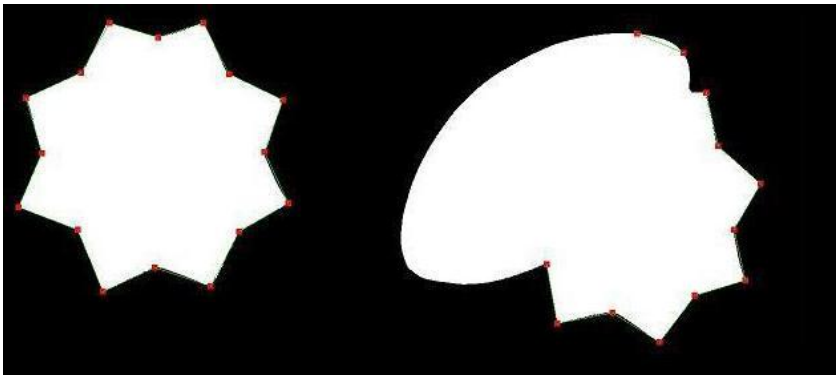

Slika 3.4: Prikazani segmenti na modelu (lijevo) i sceni (desno) za najbolju hipotezu.

iznosu parametra D_{Max} koji određuje maksimalnu dopuštenu udaljenost između transformiranog segmenta modela i segmenta scene. S povećanjem tog parametra, rasti će i broj pogrešno detektiranih segmenata. Smanjenjem tog parametra se smanjuje broj ispravno detektiranih segmenata.

Druga hipoteza tvrdi da se na sceni nalazi krug s kvalitetom iznosa 54.8%. Na sceni se krug ne nalazi, ali valja primijetiti kako kontura elipse odgovara dijelu luka kod kružnice. Možemo vidjeti da postupak detektira još dva segmenta (na

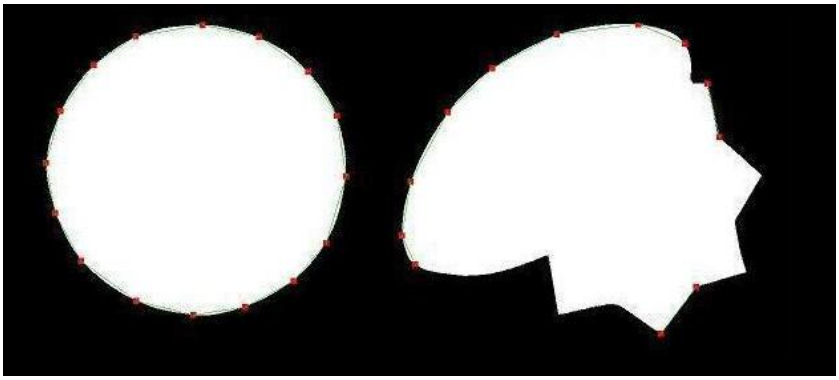

Slika 3.5: Prikazani segmenti na modelu (lijevo) i sceni (desno) za drugu najbolju hipotezu.

području zvijezde) koji bi mogli pripadati toj zamišljenoj kružnici.

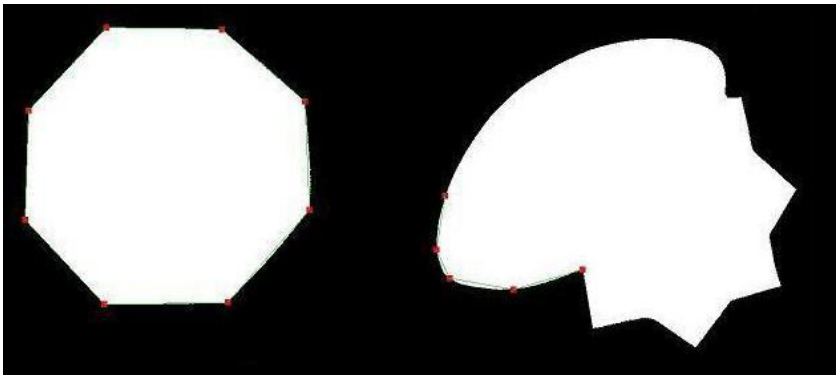

Slika 3.6: Prikazani segmenti na modelu (lijevo) i sceni (desno) za treću najbolju hipotezu.

Treća hipoteza tvrdi da se na sceni nalazi osmerokut s kvalitetom iznosa 50.3%. Kao i u prethodnom slučaju, osmerokut nije na sceni. Razlog pogrešci je sličan kao i u prethodnom slučaju tj. segmenti osmerokuta odgovaraju, unutar dozvoljene pogreške, dijelu elipse nakon rubne segmentacije.

Četvrta hipoteza tvrdi da se na sceni nalazi elipsa s kvalitetom iznosa 49.5%. To je ispravna hipoteza, te možemo vidjeti kako je velik broj segmenata u sceni ispravno detektiran, ali je i određen dio promašen. Do pogreške je došlo zbog postupka rubne segmentacije. Može se primijetiti kako su na modelu elipse dva segmenta duža i udaljenija od konture elipse, nego što je to slučaj s ostalim segmentima. Razlog tome je što implementacija postupka rubne segmentacije (podijeli i vladaj) u ovom radu nije u potpunosti invarijantna na skaliranje i

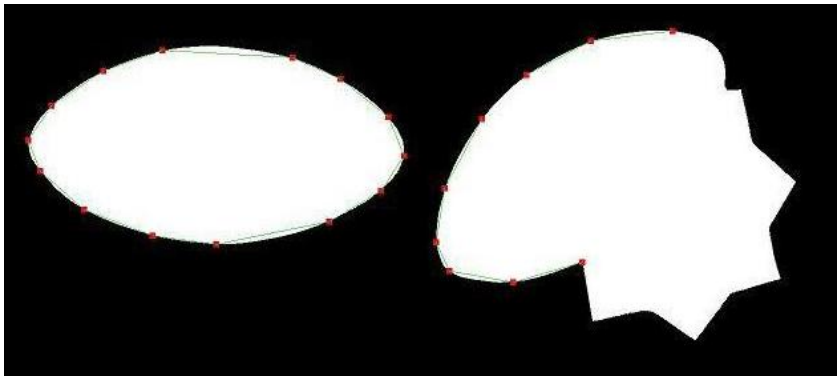

Slika 3.7: Prikazani segmenti na modelu (lijevo) i sceni (desno) za četvrtu najbolju hipotezu.

rotaciju. S obzirom na malu razliku u vjerojatnostima između druge, treće i četvrte hipoteze, ispravna detekcija preostalih segmenata, mogla je dovesti do toga da prve dvije hipoteze budu ispravne.

Spajanje segmenata je nužno zbog toga što nije pronađen način za pronalazak idealnih početnih rubnih točaka u postupku segmentacije. Posljedica je prevelik broj linearnih segmenata od stvarnog broja, što dovodi do pogreške u postupku evaluacije hipoteza. Međutim, ukoliko je kriterij prilikom usporedbe previše blag, tada će se segmenti koji nemaju sličnu orijentaciju spojiti te će se dogoditi pogreška u postupku evaluacije hipoteza. U trenutnoj implementaciji kriterij je utvrđen kao razlika između orijentacija susjednih segmenata. Ukoliko je razlika manja od praga, koji iznosi 15 stupnjeva, tada se segmenti spajaju.

Primjer kako rotacija utječe na postupak rubne segmentacije može se vidjeti na slici 3.8.

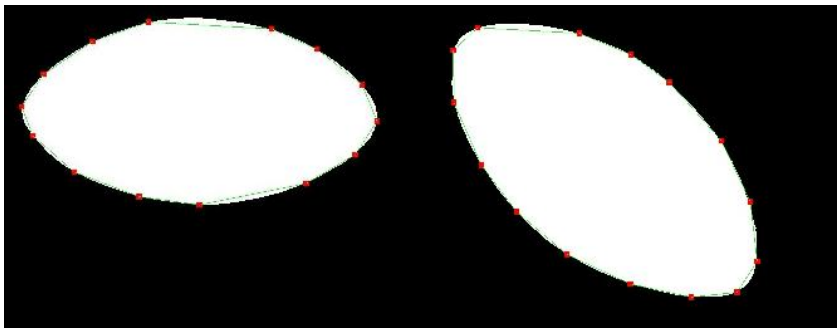

Slika 3.8: Lijevo je prikazan model elipse (0701), a desno je prikazan isti model nakon rotacije.

4. Opis programske implementacije

Implementacija je izvedena u programskom jeziku C++ koristeći Microsoft Visual Studio razvojno okruženje. Sustav razložen po komponentama može se vidjeti na slici 4.1.

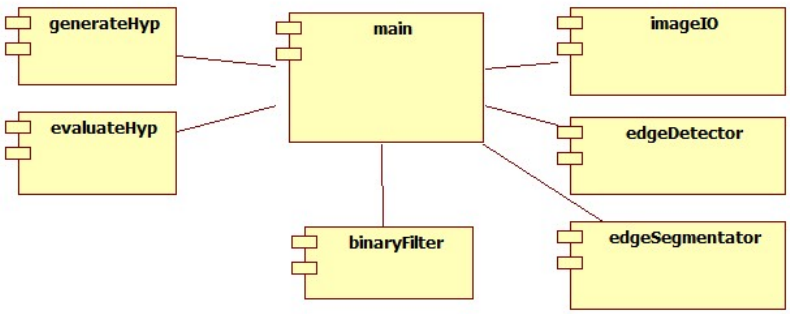

Slika 4.1: Sustav razložen po komponentama.

Za učitavanje slika koristi se OpenCV biblioteka[1], dok se za operacije s matricama koriste biblioteke Boost, Template Numerical Toolkit (TNT) i JAMA/C++ Linear Algebra Package koje su dostupne na:

- `http://www.boost.org/`,
- `http://math.nist.gov/tnt/download.html` (TNT i jama).

Trenutno je moguće učitati slike isključivo u *jpg* formatu. Jedno od potencijalnih poboljšanja sustava jest uklanjanje ovisnosti o OpenCV biblioteci te povećanje broja formata koje sustav može koristiti (npr. uvođenje *libpng*, *libjpg* i sličnih biblioteka umjesto glomazne OpenCV biblioteke).

[1] `http://opencv.willowgarage.com/wiki/`

4.1. Pokretanje implementacije

Implementacija se pokreće iz komandne linije, primjerice:

```
overlaping_obj_det.exe --modelsdir ../baza/ --scenepath \
../baza/0102.jpg -m 0101.jpg,1201.jpg
```

Obavezni parametri su:

- putanja do direktorija s bazom (`modelsdir` ili `b`),
- putanja do slike sa scenom (`scenepath` ili `s`),
- lista slika modela (`models` ili `m`).

Popis svih parametara može se dobiti pozivom:

```
overlaping_obj_det.exe -h
```

Neobavezni parametri imaju svoje predefinirane vrijednosti. No ako se koriste drugi modeli, variranje parametara može poboljšati uspješnost postupka. Program ispisuje iznos vjerojatnosti da se pojedini model nalazi na sceni, primjerice:

```
1.)0101.jpg 1
2.)1201.jpg 0.335778
```

NAPOMENA: Implementacija zahtjeva OpenCV biblioteku na računalu. Ako na računalu nije instaliran OpenCV i nemate želju instalirati ga, onda kopirajte dll datoteke: cv210.dll, cv210d.dll, cvaux210.dll, cvaux210d.dll, cxcore210.dll, cxcore210d.dll, cxts210.dll, highgui210.dll, highgui210d.dll, ml210.dll, ml210d.dll, opencv_ffmpeg210.dll, opencv_ffmpeg210d.dll, u direktorij:
`c:\Windows\System32`.

4.2. Prevođenje programskog koda

Programsko rješenje trenutno je prilagođeno samo za Visual Studio prevoditelj, no moguće ga je prepraviti na način da se omogući i prevođenje preko drugih prevoditelja (primjerice, g++ prevoditelja).

Prije postupka prevođenja potrebno je instalirati OpenCV 2.1, skinuti Boost 1.4, TNT i JAMA biblioteke te ih raspakirati na disk. Pazite da direktoriji u koji instalirate OpenCV i direktoriji u koji raspakirate preostale biblioteke nemaju prazinu u nazivu (znači, "Program Files" direktorij nije dobar izbor). Po koracima:

1. instalirajte OpenCV 2.1 (npr. u direktorij `C:\OpenCV2.1`),

2. raspakirajte Boost (npr. u direktorij `C:\includes`),

3. raspakirajte TNT i JAMA arhivu (npr. u direktorij `C:\includes\tnt`) – direktorij u koji raspakirate te datoteke **mora** se zvati "tnt" i mora sadržavati samo header (.h) datoteke TNT i JAMA biblioteka,

4. stvorite novi Visual Studio C++ *Win32 Console Application* projekt i odaberite da se radi o "empty" projektu (da VS ne generira nepotreban kod),

5. u *Source Files* i *Header Files* dodajte postojeći kod (pazite da kod unutar matrix direktorija dodate baš u direktorij a ne direktno pod "Source Files" – to se može riješiti dodavanjem novog "Filtera" matrix pod Source Files (*Desni klik > Add > New Filter*)),

6. idite na *Project properties* (desni klik na projekt > *Properties*) te tu pod "*C/C++ > General > Additional Include Directories*" dodajte (po putanjama iz 1. i 2. koraka):
   `"c:\includes\boost_1_45_0";"c:\includes";"c:\OpenCV2.1\include"`

7. u *Linker > General > Additional Library Directories* dodati:
   `C:\OpenCV2.1\lib`

8. u *Linker > Input > Additional Library Directories* dodati:
   `cv210.lib, cv210d.lib, cvaux210.lib, cvaux210d.lib, cxcore210.lib, cxcore210d.lib, cxts210.lib, highgui210.lib, highgui210d.lib, ml210.lib, ml210d.lib, opencv_ffmpeg210.lib, opencv_ffmpeg210d.lib`

9. iz direktorija `C:\OpenCV2.1\bin` kopirati sve `dll` datoteke u direktorij `C:\windows\system32`.

Sad se projekt može prevesti pokretanjem *Build* procesa. Rezultat je `exe` datoteka u Debug, odnosno Release direktoriju projekta (ovisno s kojom konfiguracijom je projekt preveden).

5. Zaključak

U ovom radu predstavljen je sustav za raspoznavanje preklapajućih dvodimenzionalnih objekata. Pri tome je boja objekata proizvoljna, moguće su rotacije, translacije i skaliranja objekata, te se na slici mogu preklapati samo dva objekta. Kao osnovne značajke korišteni su linearni segmenti konture tj. stranice poligona koji aproksimira konturu objekta. Linearni segmenti su korišteni za generiranje i rekurzivno evaluiranje hipoteza o objektima na slici.

Rezultati su obećavajući, no teško usporedivi, budući da uspješnost referentne metode iz [1] nije poznata. Pri evaluaciji problem predstavljaju objekti koji su međusobno slični na određenim dijelovima konture. Također, uspješnost metode je vrlo ovisna o korištenoj bazi objekata, pri čemu je moguće čak i da složeniji objekti poboljšavaju raspoznavanje u određenoj mjeri.

Postoje naznake da bi metoda mogla biti zadovoljavajuće uspješna nad neumjetnim primjerima (primjerice, u industriji, gdje su oblici raznovrsni).

U budućem radu poželjno bi bilo isprobati druge metode aproksimiranja konture poligonom, evaluirati druge transformacije korištene u generiranju hipoteza, eksperimentalno odrediti heuristička pravila za određivanje broja objekata koji se pojavljuju na slici, te proširiti metodu za raspoznavanje preklapanja više od 2 objekta.

6. Literatura

[1] N. Ayache i O.D. Faugeras. HYPER: A new approach for the recognition and positioning of two-dimensional objects. *Pattern Analysis and Machine Intelligence, IEEE Transactions on*, (1):44–54, 1986. ISSN 0162-8828.